



Projet d'approfondissement en Finance

Rapport final

**Etude de la contagion des risques climatiques sur les marchés
financiers - EDF**

**BOUALAM El Mehdi, DJUMENE Felix Gabin, EL HACHEM
Youssef, TATOU DEKOU Thibault**

Encadrant : HAALEBOS Ruben

[Revised 16 mai 2025]

Table des matières

Abbreviations	3
Résumé	4
Abstract	5
Introduction	6
1 Cadre théorique de l'étude	7
1.1 Revue de la littérature	7
1.2 Sélection d'un indice d'incertitude climatique	9
1.3 Modélisation de l'effet de la CPU sur les indices	10
1.3.1 Description du modèle	10
1.4 Modélisation des corrélations dynamiques	12
2 Description des données	16
2.1 Sources de données	16
2.2 Evolution des indices sectoriels	16
2.2.1 Evolution de l'indice CPU	17
2.3 Analyse préliminaire à la modélisation	18
2.3.1 Analyse des rendements des indices sectoriels	19
2.3.2 Analyse des autocorrélations des rendements	19
3 Résultats empiriques de l'étude	22
3.1 Effets de l'indice CPU sur les indices sectoriels	22
3.1.1 Impact de la CPU en niveau	22
3.1.2 Impact de la volatilité de la CPU	23
3.2 Corrélations dynamiques	25

Conclusion	28
Bibliographie	31
Annexe	33

Table des figures

2.1 Indices sectoriels	18
2.2 Rendements des indices sectoriels	19
2.3 Autocorrélations des rendements des indices sectoriels	20
2.4 Autocorrélations des carrés des rendements des indices	20
3.1 Co-mouvements de la CPU et des indices sectoriels	26
3.2 Co-mouvements de la CPUV et des indices sectoriels	27
3.3 Indice CPU	33
3.4 Représentation conjointe des indices sectoriels	33

Liste des tableaux

2.1 Statistiques descriptives des rendements des secteurs du S&P 500	21
3.1 Résultats des modèles GARCH-MIDAS avec CPU	23
3.2 Résultats des modèles GARCH-MIDAS avec CPUV	24

Liste des abréviations

ARCH	Autoregressive Conditional Heteroskedasticity
CPU	Climate Policy Uncertainty
DCC	Dynamic Conditional Correlation
ETF	Exchange-Traded Fund
EPU	Economic Policy Uncertainty
ESG	Environmental, Social, and Governance
GARCH	Generalized Autoregressive Conditional Heteroskedasticity
GPR	Geopolitical Risk Index
MIDAS	Mixed Data Sampling
PRI	Political and policy risks
SBV	Sovereign Bond Volatility
TRI	Terrorism and Geopolitical Risks

Résumé

Ce travail analyse la transmission des risques climatiques aux marchés financiers à travers une approche économétrique rigoureuse, en se focalisant sur l'impact sectoriel au sein du S&P 500. En mobilisant les modèles GARCH-MIDAS et DCC-GARCH, nous étudions l'effet de l'indice d'incertitude des politiques climatiques (CPU) et de sa volatilité sur les rendements sectoriels et leurs corrélations dynamiques.

Nos résultats montrent une hétérogénéité sectorielle marquée : certains secteurs, comme le Real Estate et les Utilities, sont fortement affectés par l'incertitude climatique, tandis que d'autres, tels que Consumer Staples et Health Care, affichent une moindre sensibilité. La volatilité de la CPU influence également différemment les secteurs, notamment Financials et Communication Services. L'analyse des corrélations dynamiques révèle une évolution temporelle liée à des événements climatiques et géopolitiques majeurs, avec une variabilité sectorielle notable.

Enfin, nous proposons d'étendre cette étude avec des modèles TVP-VAR pour analyser les effets de débordement entre secteurs, et d'évaluer la robustesse des résultats en recourant à l'indice CRMI, un indicateur des matières premières critiques pour la transition énergétique. Une exploration future intégrera aussi des modèles à changement de régime pour mieux comprendre la dynamique des dépendances.

Abstract

This study investigates the transmission of climate risks to financial markets through a rigorous econometric framework, focusing on sectoral impacts within the S&P 500. Using GARCH-MIDAS and DCC-GARCH models, we assess the effects of the Climate Policy Uncertainty index (CPU) and its volatility on sectoral returns and their dynamic correlations.

Our findings reveal significant sectoral heterogeneity : sectors such as Real Estate and Utilities are strongly influenced by climate uncertainty, while others, like Consumer Staples and Health Care, exhibit lower sensitivity. The CPU's volatility also differentially affects sectors, notably Financials and Communication Services. Dynamic correlation analysis shows time-varying patterns linked to major climatic and geopolitical events, with notable sectoral differences in correlation volatility.

Future research will extend the analysis with Time-Varying Parameter VAR models to capture volatility spillovers across sectors and validate findings using the Critical Raw Materials Index (CRMI), which tracks key metals for the energy transition. Additionally, regime-switching DCC-GARCH models will be considered to better capture dependency dynamics during periods of strong versus weak climate risk linkages.

Introduction

Dans le cadre de la transition vers une économie bas carbone, l'économie française investit massivement pour relever des défis technologiques, environnementaux et sociaux. Les entreprises et institutions cherchent à prendre en compte l'impact des risques climatiques dans la gestion de leurs portefeuilles d'actifs à long terme, conciliant durabilité et performance économique. Des études sont alors réalisées dans l'optique de définir des stratégies alignées sur les politiques de gestion des risques, tout en intégrant les impacts financiers du changement climatique pour garantir la résilience des investissements. Actuellement, les données qui permettent de quantifier les impacts financiers des risques physiques et de transition sont rares. En effet, même si le nombre de catastrophes naturelles liées au changement climatique est en augmentation, les effets majeurs ne se manifesteront qu'à long terme. De plus, bien que des mesures initiales d'adaptation et de décarbonatation soient mises en place (comme par exemple l'interdiction de la commercialisation des véhicules thermiques d'ici 2035), des mesures plus ambitieuses sont encore retardées. Par conséquent, l'intégralité du risque climatique n'est pas encore prise en compte par les marchés financiers. Cependant, lors d'événements spécifiques tels que les Conférences des Parties (COP), les marchés et certaines entreprises considérées comme exposées au risque climatique voient leur volatilité augmenter et leurs prix diminuer. Cela permet de révéler une partie du risque financier lié à la perception du changement climatique.

Dans cette étude, l'on souhaite examiner comment certains événements climatiques peuvent engendrer un risque susceptible de se propager aux marchés financiers. Pour ce faire il est nécessaire de disposer d'un indicateur mesurant l'incertitude sur le climat ; les indices d'actualité climatique semblent appropriés. Il sera donc question de décrire la construction de l'indice retenu, puis d'analyser la transmission de l'incertitude climatique sur les marchés financiers via cet indice, son évolution dans le temps et suivant les différents secteurs.

Chapitre 1 —

Cadre théorique de l'étude

Ce chapitre présente le socle théorique sur lequel repose ce travail. Il fait un état des lieux sur la littérature existante sur la thématique étudiée et décline la méthodologie retenue pour répondre à la problématique de ce travail.

1.1 Revue de la littérature

L'impact des risques climatiques sur les marchés financiers constitue un sujet de recherche crucial, exploré par de nombreuses études.

Jia, Guo, et Jin (2024) ont examiné comment l'incertitude des politiques climatiques, mesuré via le Climate Policy Uncertainty index (CPU) influence la volatilité des obligations souveraines (SBV) dans 43 économies entre 2012 et 2021. Leur travail s'appuie sur des modèles économétriques tels que GARCH-MIDAS et DCC-GARCH pour analyser les relations complexes entre la CPU, sa volatilité (CPUv), et la SBV. Les résultats montrent que, bien qu'une augmentation de la CPU réduise généralement la SBV, une hausse de la CPUp tend à l'amplifier, en particulier dans les économies développées. Ces résultats mettent également en lumière l'importance des effets de débordement, renforcés par des événements internationaux tels que l'Accord de Paris et la pandémie de COVID-19.

Ensuite, Usman Ghani, Bho Zhu, Feng Ma, et Maria Ghani (2024) ont approfondi les interactions entre les indices sectoriels et les facteurs d'incertitude climatique en utilisant des extensions du modèle GARCH-MIDAS. Ils ont montré que les indices CPU et GPR, lorsqu'ils sont intégrés dans les prédictions, offrent une vision plus complète des dynamiques de volatilité à long terme. En combinant ces approches avec celles discutées par Pereira et al., leur travail contribue à une compréhension intégrée des dynamiques

financières dans un contexte de changement climatique.

Par ailleurs, Engle, Giglio, Kelly, Lee, et Stroebel (2017) ont proposé une approche innovante pour la couverture des risques climatiques à travers des portefeuilles dynamiques alignés sur les nouvelles climatiques. Plutôt que d'utiliser des options traditionnelles, ces portefeuilles intègrent des actions pondérées selon leurs caractéristiques ESG. Les résultats démontrent que ces portefeuilles surpassent les ETF en termes de performance et de résilience, tout en identifiant les secteurs les plus exposés aux événements climatiques. En ce sens, leur travail illustre une application concrète des implications des risques climatiques sur la gestion des portefeuilles.

Sur un sujet similaire, Zhang et Wei (2016) se sont intéressés aux relations entre le marché pétrolier (WTI) et les marchés boursiers américains et chinois sur la période 1991-2016. Utilisant des modèles VAR-BEKK-GARCH et de copules, ils ont démontré que les relations entre ces marchés varient considérablement dans le temps et sont influencées par des événements majeurs, tels que la crise financière de 2008. Ils montrent que le marché pétrolier joue un rôle dominant dans la transmission de la volatilité, particulièrement vers les marchés américains, bien que des effets bidirectionnels aient émergé entre les marchés chinois et américains vers la fin de la période étudiée. Ces résultats, en convergence avec ceux de Jia et al., soulignent les interdépendances croissantes entre les risques climatiques et financiers.

Dans un autre registre, Ghani, Zhu, Ma, et Ghani (2024) ont étudié l'impact de la CPU sur la volatilité des indices sectoriels et des fonds négociés en bourse (ETFs) liés à l'énergie propre. Utilisant le modèle GARCH-MIDAS, ils ont démontré que l'indice CPU améliore significativement les prédictions de volatilité pour des indices tels que ceux des énergies renouvelables ou du transport. En outre, les facteurs EPU (Economic Policy Uncertainty) et GPR (Geopolitical Risk) renforcent la robustesse des modèles. Ces résultats, en accord avec ceux d'Engle et al., mettent en lumière l'importance des outils méthodologiques avancés pour modéliser l'impact des incertitudes climatiques.

Pereira, Thomas, et Silva (2023) ont adopté une perspective plus large, en explorant les opportunités et impacts financiers des risques climatiques. Ils distinguent les risques de transition, associés à l'adoption d'une économie bas carbone, et les risques physiques, liés aux événements climatiques aigus ou chroniques. Ces auteurs soulignent que les entreprises

peuvent tirer parti de ces risques en améliorant leur efficacité énergétique, en diversifiant leurs activités et en développant leur résilience. Ce cadre offre un contexte plus général pour les analyses précédentes, en mettant en avant les stratégies pratiques d'adaptation aux risques climatiques.

En synthèse, les recherches examinées convergent sur l'importance de l'incertitude climatique dans les dynamiques financières. Les modèles avancés, tels que GARCH-MIDAS ou de copules, permettent de capturer les effets complexes de débordement et les interdépendances entre les marchés. Ces études soulignent également la nécessité de stratégies innovantes, telles que les portefeuilles alignés sur les caractéristiques ESG, pour répondre aux défis posés par les risques climatiques. En développant des outils plus sophistiqués et en se concentrant sur des données plus granulaires, les recherches futures pourront approfondir notre compréhension des interactions entre les risques climatiques et financiers.

1.2 Sélection d'un indice d'incertitude climatique

Afin d'examiner comment les événements climatiques peuvent engendrer un risque susceptible de se propager aux marchés financiers, l'approche retenue est d'utiliser un indice climatique qui agrège et quantifie ces événements et de mesurer la transmission de ce risque via cet indice. Il existe plusieurs indices visant à capter le changement climatique. Les plus connus sont : le Climate Policy Uncertainty Index (CPU) et les Climate Risk Indexes (TRI&PRI). La revue consultée suggère que l'indice CPU est le plus approprié. Il est plus général car il s'intéresse aux risques climatiques dans leur ensemble et ne distingue donc pas le risque de transition du risque physique. Il permet donc de mieux capter l'incertitude climatique globale. Cette caractéristique nous intéresse car les entreprises font face simultanément aux deux types de risques dans leurs stratégies et ils cherchent généralement à avoir une vision d'ensemble de ce risque. Enfin, il est construit sur la base des articles de huit grands journaux américains, contrairement aux TRI&PRI (qui s'appuient respectivement sur les articles de 50 à 60 sources médiatiques internationales pour le PRI, et sur les articles de 10 à 15 journaux majeurs pour le TRI).

1.3 Modélisation de l'effet de la CPU sur les indices

Généralement, les modèles GARCH et à volatilité stochastiques sont utilisés pour modéliser la volatilité d'un indice financier. L'inconvénient avec ces modèles est qu'ils ne capturent que la volatilité à court terme. Afin de pallier à cet inconvénient, les auteurs Ding et Granger (1996), Engle et Lee (1999), Maheu (2005) et Ding (2016) ont démontré que les modèles obtenus en décomposant la variance conditionnelle en une composante long terme et une composante court terme permettent de capturer la volatilité de long terme. En s'inspirant de l'approche MIDAS (Mixed Data Sampling), les auteurs Engle et al. (2013) ont proposé le modèle GARCH-MIDAS qui non seulement distingue les mouvements de long et court terme, mais permet aussi de lier la volatilité de long terme à d'autres variables explicatives exogènes. Ce modèle sera utilisé pour étudier l'impact de la CPU (en niveau) ainsi que la volatilité de la CPU (c'est-à-dire la variabilité de l'incertitude) sur les rendements des indices sectoriels.

1.3.1 Description du modèle

Soit $r_{i,t}$ le logarithme des rendements journaliers d'un indice financier où i est la journée considérée pour le mois t . Le modèle GARCH-MIDAS modélise $r_{i,t}$ comme suit :

$$r_{i,t} = \mu + \sqrt{\tau_t g_{i,t}} \varepsilon_{i,t}, \quad \forall i = 1, \dots, N_t. \quad (1.1)$$

Dans cette équation,

- τ_t est la composante de volatilité de long terme,
- $g_{i,t}$ est la composante de volatilité à court terme,
- $\varepsilon_{i,t} | \Phi_{i-1,t} \sim \mathcal{N}(0, 1)$ où $\Phi_{i-1,t}$ désigne les informations disponibles jusqu'à la période $(i-1)$ du mois t ,
- N_t correspond au nombre de jours de trading dans le mois t et
- μ représente l'espérance des rendements $E_{i-1,t}(r_{i,t})$ qui est supposée constante.

La composante de la volatilité à court terme $g_{i,t}$ est modélisée par un processus GARCH (1,1) spécifié par :

$$g_{i,t} = (1 - \alpha - \beta - \gamma/2) + (\alpha + \gamma \mathbf{1}_{\{r_{i-1,t} - \mu < 0\}}) \frac{(r_{i-1,t} - \mu)^2}{\tau_t} + \beta g_{i-1,t}, \quad (1.2)$$

sous les contraintes

$$\alpha > 0, \beta > 0 \text{ et } \alpha + \beta + \gamma/2 < 1. \quad (1.3)$$

Le paramètre γ contient les informations sur l'asymétrie du modèle. On considère le paramètre γ nul en général. La composante de la volatilité à long terme τ_t , est modélisée comme suit :

$$\log(\tau_t) = m + \theta \sum_{k=1}^K \psi_k(\omega) X_{t-k}, \quad (1.4)$$

Dans cette équation,

- une forme logarithmique peut être utilisée pour la volatilité à long terme $\log(\tau_t)$ afin d'éviter les effets négatifs dans la composante de volatilité au cours du processus de prévision,
- Le schéma de pondération dans les équations $\psi_k(\omega)$ est défini par la fonction :

$$\psi_k(\omega) = \frac{(1 - \frac{k}{K})^{\omega-1}}{\sum_{j=1}^K (1 - \frac{j}{K})^{\omega-1}}. \quad (1.5)$$

Les poids $(\psi_k)_{k \in \{1, \dots, K\}}$ vérifient,

$$\psi_k \geq 0, \text{ pour } k = 1, \dots, K \text{ et } \sum_{k=1}^K \psi_k = 1, \quad (1.6)$$

- K représente le nombre de périodes sur lesquelles la volatilité est estimée. La valeur optimale maximale du retard K est déterminée en utilisant les critères AIC et BIC.
- X_t représente les variables exogènes généralement de fréquence mensuelle ou trimestrielle.

Ce modèle est généralement estimé via méthode du quasi-maximum de vraisemblance. En partant de l'équation (1.1), le modèle peut être estimé en considérant la vraisemblance conditionnelle aux observations passées. En effet, en supposant la normalité des résidus,

la densité conditionnelle des rendements s'écrit :

$$f(r_{i,t}|\Phi_{i-1,t}, r_{i,t-1}, r_{i,t-2}, \dots) = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{\tau_t g_{i,t}}} \exp\left(-\frac{1}{2} \frac{(r_{i,t} - \mu)^2}{\tau_t g_{i,t}}\right) \quad (1.7)$$

On en déduit la fonction de log-vraisemblance donnée par :

$$Flv(\psi) = -\frac{1}{2} \sum_{t=1}^T \sum_{i=1}^{N_t} \left[\log(2\pi) + \log(g_{i,t}(\Phi)\tau_t(\Phi)) + \frac{(r_{i,t} - \mu)^2}{g_{i,t}(\Phi)\tau_t(\Phi)} \right] \quad (1.8)$$

où $\Phi = (\mu, \alpha, \beta, m, \theta, w_1, w_2)$ représente le vecteur des paramètres à estimer.

Par ailleurs, on s'intéressera au ratio de variance (v.r) défini par l'équation ci-dessous pour évaluer la contribution de la CPU (ou CPUv) à la volatilité de long terme des différents indices sectoriels.

$$v.r = \frac{\text{var}(\log \tau_t)}{\text{var}(\log(g_t \tau_t))}, \quad \text{where} \quad g_t = \sum_{i=1}^{N_t} g_{it}. \quad (1.9)$$

1.4 Modélisation des corrélations dynamiques

Pour examiner les coefficients dynamiques de corrélation conditionnelle entre la CPU (ou la CPUv) et les rendements des différents indices sectoriels, cette étude utilise le modèle DCC-GARCH proposé par Engle (2002). Cette approche utilise une estimation des paramètres en deux étapes simples et paramètre directement la matrice de corrélation conditionnelle plutôt que la matrice de covariance. Elle préserve la flexibilité du modèle GARCH univarié, réduit la complexité des paramètres et évite les défis computationnels liés aux modèles GARCH multivariés.

Considérons $X_t = (X_{1t}, X_{2t})'$ le processus stochastique bivarié constitué de la CPU (ou la CPUv) et un indice sectoriel. Il est nécessaire de calculer les co-mouvements entre la CPU et chaque indice sectoriel séparément.

$$X_t = \mu_t(\theta) + \varepsilon_t, \quad \varepsilon_t | \Omega_{t-1} \sim N(0, H_t), \quad (1.10)$$

$$\varepsilon_t = H_t^{\frac{1}{2}} z_t, \quad z_t \sim N(0, I), \quad (1.11)$$

$$H_t = D_t R_t D_t, \quad (1.12)$$

où $\mu_t(\theta) = E_{t-1}(X_t) = (\mu_{1t}, \mu_{2t})'$ désigne l'expérience conditionnelle de X_t . La matrice de variance-covariance conditionnelle temporelle de ε_t est $H_t = \{h_{ijt}\}_{i,j=1,2}$. H_t peut être calculée en utilisant l'équation (1.12), où $D_t = \text{diag}\{\sqrt{h_{iit}}\}$ est une matrice diagonale. R_t est la matrice des coefficients de corrélation conditionnelle variable dans le temps, qui constitue l'objet principal de l'estimation. Les paramètres sont estimés en deux temps. Premièrement, on estime h_{iit} via le modèle GARCH (1,1) suivant :

$$h_{iit} = \gamma_i + \alpha_i \varepsilon_{i,t-1}^2 + \beta_i h_{ii,t-1}, \quad i = 1, 2. \quad (1.13)$$

Ensuite, en utilisant les résultats de la première étape, on estime R_t en utilisant le modèle bivarié DCC (1,1) suivant :

$$Q_t = (q_{ijt}) = (1 - \alpha - \beta)Q + \alpha \nu_{t-1} \nu_{t-1}' + \beta Q_{t-1}, \quad (1.14)$$

$$R_t = (\rho_{ijt}) = \left(\frac{q_{ijt}}{\sqrt{q_{iit} q_{jtt}}} \right) = \text{diag}(Q_t)^{-\frac{1}{2}} Q_t \text{diag}(Q_t)^{-\frac{1}{2}}, \quad (1.15)$$

où $\nu_t = (\nu_{1t}, \nu_{2t})' = \left(\frac{\varepsilon_{1t}}{\sqrt{h_{11t}}}, \frac{\varepsilon_{2t}}{\sqrt{h_{22t}}} \right)'$ est le vecteur ε_t normalisé à partir de l'équation (1.13) ; $Q = \frac{1}{T} \sum_{t=1}^T \nu_t \nu_t'$ la matrice de variance-covariance inconditionnelle de taille $N \times N$ qui est invariante dans le temps . Aussi, $0 \leq \alpha, \beta \leq 1$, et $\alpha + \beta < 1$. Le modèle DCC est estimé par maximum de vraisemblance, en supposant que ε_t est distribué suivant une loi normale multivariée ou une loi de Student multivariée.

Le modèle DCC peut être formulé comme la spécification statistique suivante :

$$r_t | \mathcal{F}_{t-1} \sim \mathcal{N}(0, D_t R_t D_t), \quad (1.16)$$

$$D_t^2 = \text{diag}\{\omega_i\} + \text{diag}\{\alpha_i\} \odot r_{t-1} r_{t-1}' + \text{diag}\{\beta_i\} \odot D_{t-1}^2, \quad (1.17)$$

$$\tilde{\epsilon}_t = D_t^{-1} r_t, \quad (1.18)$$

$$Q_t = \bar{Q}(1 - \alpha - \beta) + \alpha \tilde{\epsilon}_{t-1} \tilde{\epsilon}_{t-1}' + \beta Q_{t-1}, \quad (1.19)$$

$$R_t = \text{diag}\{Q_t\}^{-1/2} Q_t \text{diag}\{Q_t\}^{-1/2}. \quad (1.20)$$

L'hypothèse de normalité dans la première équation donne lieu à une fonction de vraisemblance. Sans cette hypothèse, l'estimateur aura toujours une interprétation de

Quasi-Maximum de Vraisemblance (QML). La deuxième équation exprime simplement l'hypothèse que chaque actif suit un processus GARCH univarié. La log-vraisemblance s'exprime alors comme suit :

$$L = -\frac{1}{2} \sum_{t=1}^T \left[n \log(2\pi) + \log |H_t| + r'_t H_t^{-1} r_t \right] \quad (1.21)$$

$$= -\frac{1}{2} \sum_{t=1}^T \left[n \log(2\pi) + \log |D_t R_t D_t| + r'_t D_t^{-1} R_t^{-1} D_t^{-1} r_t \right] \quad (1.22)$$

$$= -\frac{1}{2} \sum_{t=1}^T \left[n \log(2\pi) + 2 \log |D_t| + \log |R_t| + \tilde{\epsilon}'_t R_t^{-1} \tilde{\epsilon}_t \right] \quad (1.23)$$

$$= -\frac{1}{2} \sum_{t=1}^T \left[n \log(2\pi) + 2 \log |D_t| + r'_t D_t^{-2} r_t - \tilde{\epsilon}'_t \tilde{\epsilon}_t + \log |R_t| + \tilde{\epsilon}'_t R_t^{-1} \tilde{\epsilon}_t \right], \quad (1.24)$$

qui peut simplement être maximisée sur les paramètres du modèle. Cependant, l'un des objectifs de cette formulation est de permettre au modèle d'être estimé plus facilement même lorsque la matrice de covariance est très grande. Soit les paramètres dans D notés θ et les paramètres additionnels dans R notés ϕ . La log-vraisemblance peut être écrite comme la somme d'une partie volatilité et d'une partie corrélation :

$$L(\theta, \phi) = L_V(\theta) + L_C(\theta, \phi). \quad (1.25)$$

Le terme de volatilité est

$$L_V(\theta) = -\frac{1}{2} \sum_t \left[n \log(2\pi) + \log |D_t|^2 + r'_t D_t^{-2} r_t \right], \quad (1.26)$$

et le composant de corrélation est

$$L_C(\theta, \phi) = -\frac{1}{2} \sum_t \left[\log |R_t| + \tilde{\epsilon}'_t R_t^{-1} \tilde{\epsilon}_t - \tilde{\epsilon}'_t \tilde{\epsilon}_t \right]. \quad (1.27)$$

La partie volatilité de la vraisemblance est apparue comme la somme des vraisemblances GARCH individuelles

$$L_V(\theta) = -\frac{1}{2} \sum_t \sum_{i=1}^n \left[\log(2\pi) + \log(h_{i,t}) + \frac{r_{i,t}^2}{h_{i,t}} \right], \quad (1.28)$$

qui est conjointement maximisée en maximisant séparément chaque terme. La deuxième

partie de la vraisemblance est utilisée pour estimer les paramètres de corrélation. Comme les résidus au carré ne dépendent pas de ces paramètres, ils n'entrent pas dans les conditions du premier ordre et peuvent être ignorés. L'approche en deux étapes pour maximiser la vraisemblance est de trouver

$$\hat{\theta} = \arg \max \{L_V(\theta)\}, \quad (1.29)$$

puis de prendre cette valeur comme donnée dans la deuxième étape :

$$\max_{\phi} \{L_C(\hat{\theta}, \phi)\}. \quad (1.30)$$

Sous des conditions de régularité raisonnables, la cohérence de la première étape assurera la cohérence de la deuxième étape. En clair, le maximum de la deuxième étape sera une fonction des estimations des paramètres de la première étape, donc si la première étape est cohérente, la deuxième étape sera cohérente tant que la fonction est continue dans un voisinage des vrais paramètres.

Chapitre 2 —

Description des données

Ce chapitre présente les sources de données utilisées. Il donne un premier aperçu sur les données et présente quelques analyses menées en amont de la modélisation.

2.1 Sources de données

Les données utilisées dans le cadre de cette étude sont : l'indice CPU mensuel et les rendements journaliers des différents indices sectoriels du S&P Dow Jones. L'indice CPU utilisé ici est celui développé par Gavriilidis (2021) à partir des articles de huit grands journaux américains. L'étude se focalise sur onze indices sectoriels (Communication Services, Consumer Discretionary, Consumer Staples, Energy, Financials, Health Care, Industrials, Information Technology, Materials, Real Estate, Utilities). Les données sur les différents indices sectoriels peuvent être retrouvées ici. Dès lors, en notant $P_{i,t}$ la performance d'un indice pour le jour i du mois t , l'étude utilise les rendements journaliers $r_{i,t}$ calculés comme suit : $r_{i,t} = 100 (\ln P_{i,t} - \ln P_{i-1,t})$. L'échantillon retenu s'étend sur la période d'octobre 2014 à Novembre 2024. Il couvre des évènements majeurs tels que la signature et l'implémentation de l'Accord de Paris et la pandémie de COVID-19.

2.2 Evolution des indices sectoriels

La figure 2.1 ci-dessous et la figure 3.4 en annexe sont des illustrations de l'évolution des différents indices sectoriels étudiés sur la période d'analyse retenue. S'agissant du secteur **Communication Services**, on observe qu'après une croissance régulière jusqu'en 2022, ce secteur montre une volatilité importante, suivie d'une stabilisation et d'une

reprise récente. Le secteur **Consumer Discretionary** quant à lui affiche une forte tendance haussière avec des fluctuations notables, particulièrement autour de la période de la pandémie de 2020, suivies d'une reprise marquée. Pour le secteur **Consumer Staples**, une progression régulière avec une volatilité relativement faible est observée, reflétant la stabilité typique des biens de consommation de base. Le secteur de l'**Energie** est caractérisé par une forte volatilité, avec des baisses importantes autour de 2020 (probablement liées à la chute des prix du pétrole), suivies d'une reprise significative. Pour le secteur **Financials** on relève une croissance notable, avec une chute marquée autour de 2020, suivie d'une reprise constante. Le secteur **Health Care** présente une tendance haussière régulière avec une volatilité modérée, indiquant la résilience de ce secteur. Le secteur **Industrials** montre une progression forte et régulière, avec un pic de volatilité notable autour de 2020, suivie d'une nette reprise. Le secteur **Information Technology** affiche une croissance exceptionnelle et quasi-continue, soulignant son rôle dominant dans le marché. Le secteur **Materials** affiche une reprise marquée après la volatilité de 2020, avec une croissance régulière depuis. Le secteur **Real Estate** présente une forte volatilité avec des baisses notables autour de 2020, suivies d'une stabilisation et d'une reprise. Le secteur **Utilities** enfin montre quant à lui une tendance haussière modérée, avec une volatilité notable autour de 2020, mais globalement stable. De façon générale, on note :

- **L'impact de 2020** : Tous les secteurs semblent avoir été impactés par les événements de 2020 (notamment la pandémie de COVID-19), avec des chutes marquées suivies de reprises.
- **Des différences sectorielles** : Les secteurs comme Information Technology et Health Care montrent une résilience et une croissance plus forte, tandis que les secteurs comme Energy et Real Estate sont plus volatiles.
- **Une tendance générale** : Une tendance haussière est visible dans presque tous les secteurs, reflétant une croissance globale du marché sur la période étudiée.

2.2.1 Evolution de l'indice CPU

L'indice CPU présente une tendance haussière sur la période 2014-2024 comme on peut le voir sur la figure 3.3 en annexe. Cependant, cette progression est marquée par des phases de forte volatilité et des fluctuations importantes. Entre 2014 et 2016, on ob-

serve une croissance modérée et relativement stable, avec des oscillations limitées. Entre 2016 et 2018 on relève une augmentation marquée de l'indice, faisant suite probablement à l'Accord de Paris sur le climat, suivie d'une stabilisation temporaire. La volatilité de l'indice s'accroît entre 2018 et 2020 avec des fluctuations plus amples. L'accroissement devient plus important entre 2020 et 2022, correspondant vraisemblablement à des événements majeurs, comme la pandémie de COVID-19. Ces variations indiquent une réponse marquée de l'indice aux chocs exogènes. Entre 2022 et 2024, l'indice reste volatile, avec des fluctuations moindres, suggérant un retour progressif à une relative stabilité. C'est la série stationarisée (en passant au logarithme) qui est utilisée dans l'étude.

Le premier objectif de ce travail étant d'investiguer l'impact de l'indice CPU sur la volatilité des différents indices sectoriels, il est primordial de réaliser certaines analyses préliminaires en vue de la modélisation. Dans l'optique d'évaluer cet impact, la littérature suggère l'utilisation d'un modèle GARCH-MIDAS. Toutefois l'estimation de ce dernier requiert que les séries considérées valident un certain nombre de critère.

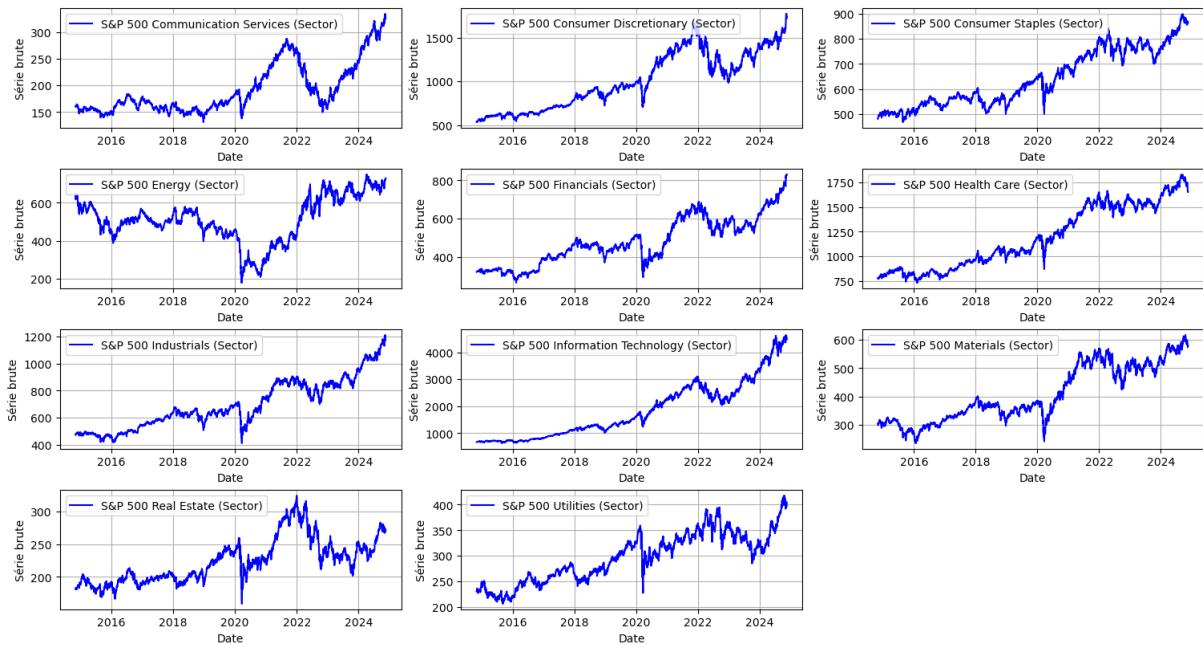


FIGURE 2.1 – Indices sectoriels

2.3 Analyse préliminaire à la modélisation

La modélisation GARCH-MIDAS impose de disposer de séries stationnaires, qui présentent des hétéroscédasticités conditionnelles. Avant de procéder à un quelconque test,

il paraît important de faire une description des rendements des indices sectoriels étudiés.

2.3.1 Analyse des rendements des indices sectoriels

Le figure 2.2 ci-dessous montre que tous les secteurs présentent des rendements centrés autour de zéro, ce qui est attendu pour les séries de rendements financiers. Ces rendements semblent ainsi à première vue stationnaires. Toutefois, une volatilité marquée est visible autour de l'année 2020, probablement liée à la pandémie de COVID-19. On note également des différences au niveau des secteurs. Notamment, les secteurs comme **Energy, Real Estate, et Materials** montrent une volatilité plus élevée, avec des mouvements plus extrêmes, notamment en 2020 où ces secteurs semblent avoir été les plus touchés. A contrario, des secteurs comme **Consumer Staples et Utilities** ont des rendements plus stables, reflétant leur nature défensive.

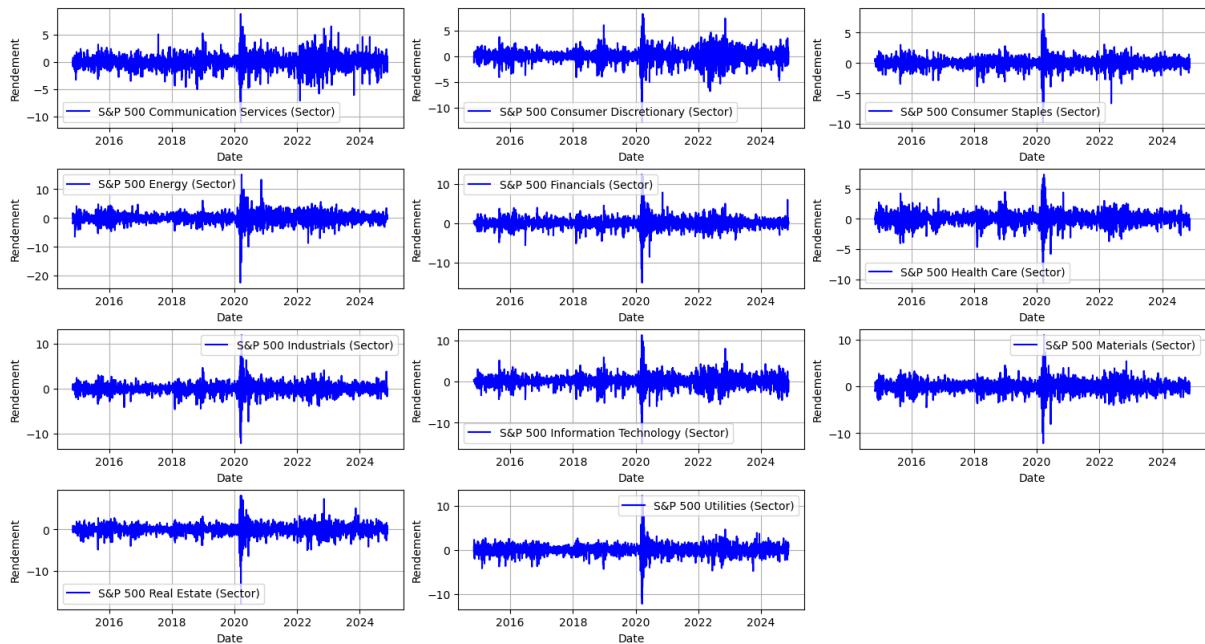


FIGURE 2.2 – Rendements des indices sectoriels

2.3.2 Analyse des autocorrélations des rendements

La figure 2.3 ci-après présente les fonctions d'autocorrélation des rendements des différents indices sectoriels étudiés. On remarque de prime abord que les autocorrélations de ces rendements sont nulles. Cette observation est en accord avec l'hypothèse d'efficience des marchés qui postule que les rendements doivent être indépendants.

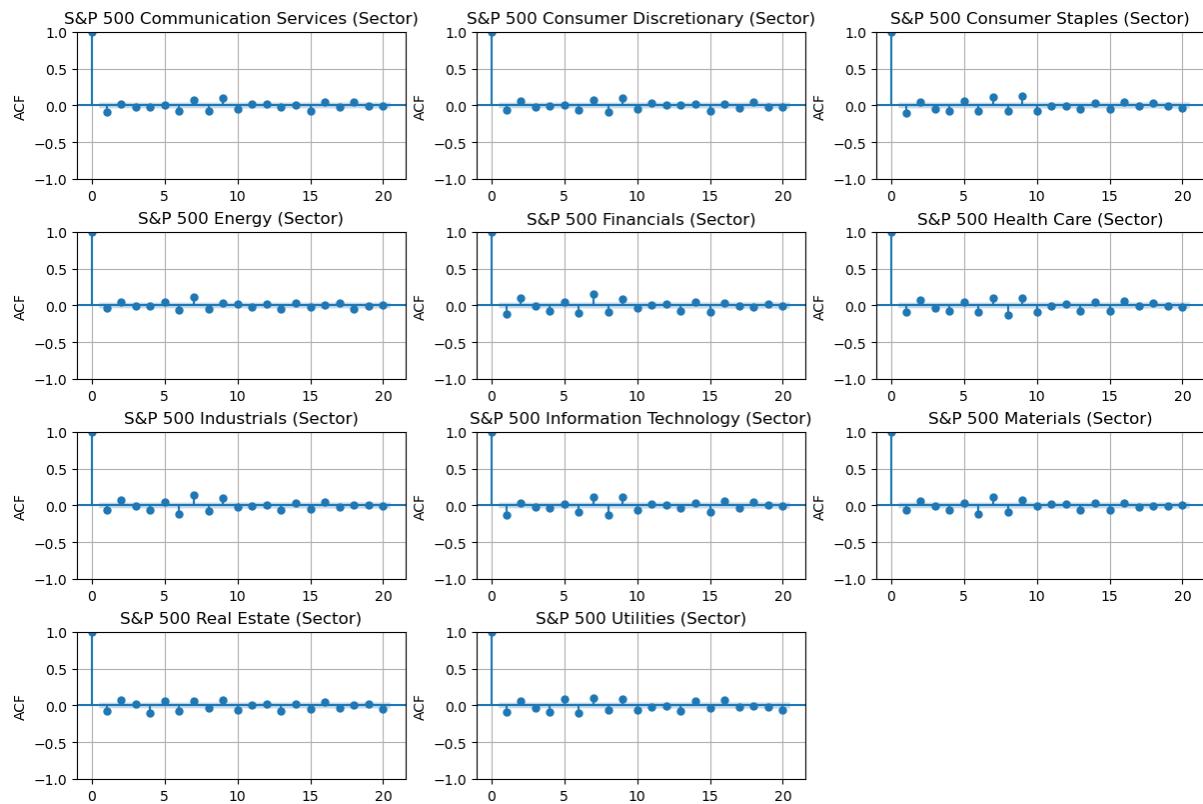


FIGURE 2.3 – Autocorrélations des rendements des indices sectoriels

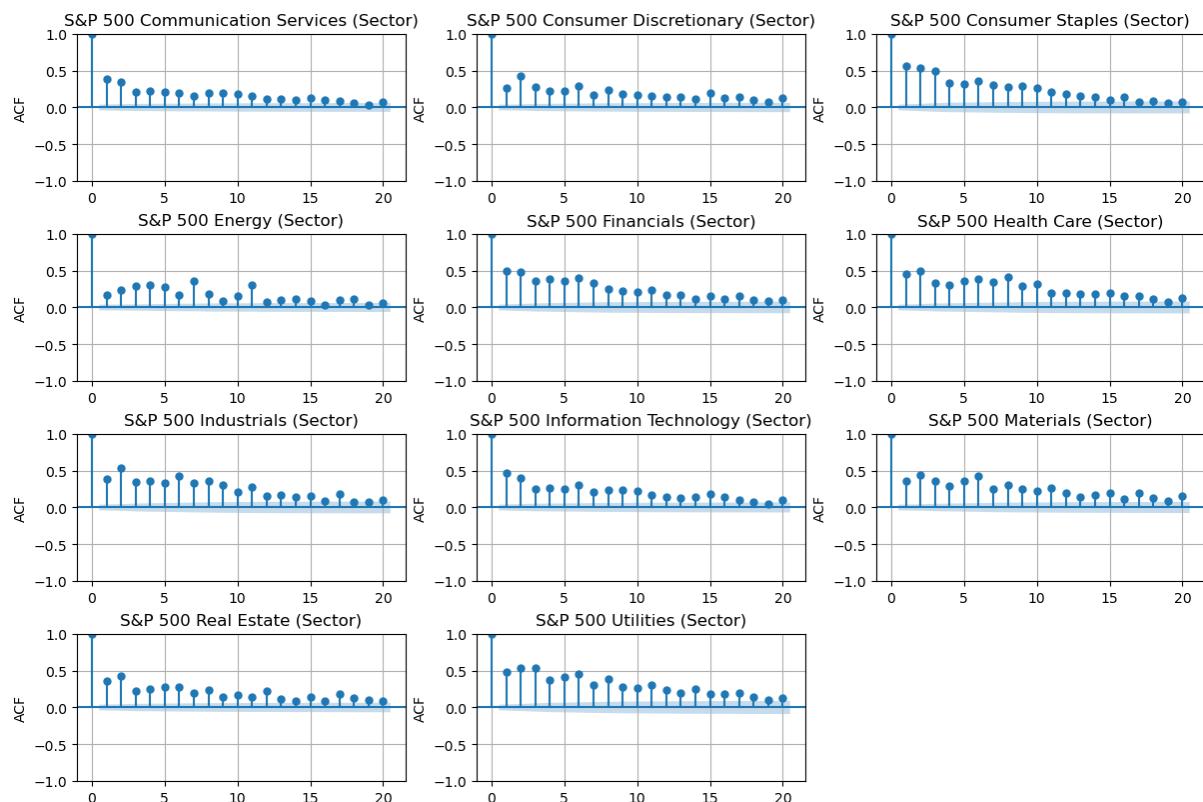


FIGURE 2.4 – Autocorrélations des carrés des rendements des indices

En revanche, en s'intéressant aux autocorrélations des carrés des rendements (voir figure 2.4), on observe que celles-ci ne sont plus nulles. En effet, on relève une décroissance lente des coefficients d'autocorrélation dans la plupart des graphiques, ce qui indique une persistance dans la volatilité. Cela suggère que les périodes de forte volatilité ont tendance à être suivies par d'autres périodes de volatilité élevée. Aussi, les autocorrélations significatives pour plusieurs décalages (lags) suggèrent la présence d'un phénomène d'**hétéroscléasticité conditionnelle** (effets ARCH ou GARCH). Ce phénomène est typique des séries financières, où la variance des rendements n'est pas constante dans le temps. On note également que cette persistance de la volatilité varie selon les secteurs. En clair, les secteurs comme **Energy, Materials et Real Estate** montrent une volatilité plus persistante, tandis que des secteurs plus stables comme **Utilities et Consumer Staples** affichent une décroissance plus rapide. Ces résultats donnent lieu de penser que des modèles comme ARCH/GARCH seraient adaptés pour capturer la dynamique de la volatilité dans ces séries.

TABLE 2.1 – Statistiques descriptives des rendements des secteurs du S&P 500

Secteur	Mean	Std. Dev	Min	Max	Skewness	Kurtosis	J-B Stat	J-B P-Value	ADF Stat	ADF P-Value	ARCH Stat	ARCH P-Value
S&P 500 Communication Services	0.028229	1.346603	-11.030047	8.802128	-0.407430	5.827832	3647.442987	0.0	-15.908097	8.182953e-29	556.898624	3.374180e-105
S&P 500 Consumer Discretionary	0.046204	1.347879	-12.877170	8.286203	-0.717550	5.757313	6555.463314	0.0	-10.877228	1.322222e-29	654.644467	8.566006e-126
S&P 500 Consumer Staples	0.023294	1.925314	-9.690215	8.074723	-0.474026	15.204774	24454.814489	0.0	-15.789363	1.106929e-28	1118.840120	1.704292e-224
S&P 500 Energy	0.005140	1.894000	-22.417189	15.110788	-0.824055	15.567753	25811.638994	0.0	-16.825264	1.169596e-29	724.758650	1.271238e-140
S&P 500 Financials	0.037583	1.405525	-15.070693	12.425065	-0.569502	15.990685	27070.597104	0.0	-10.586444	7.610716e-18	935.748651	1.925657e-185
S&P 500 Health Care	0.029740	1.060204	-10.527407	7.331816	-0.393816	9.650929	9876.137895	0.0	-17.116378	7.360814e-30	988.178814	1.294629e-196
S&P 500 Industrials	0.037576	1.237602	-12.155005	10.343763	-0.596834	14.082717	21038.524817	0.0	-16.425755	1.709638e-28	1019.221530	2.090160e-150
S&P 500 Information Technology	0.075170	1.495300	-14.983344	11.033365	-0.493038	8.571509	8370.524823	0.0	-16.513316	1.246263e-29	867.238448	7.325936e-171
S&P 500 Materials	0.025366	1.305335	-12.146958	11.033365	-0.490380	9.571509	9751.303975	0.0	-16.513316	6.000668e-29	762.037487	1.602114e-148
S&P 500 Real Estate	0.015992	1.303224	-18.091023	8.280162	-1.163824	20.451265	44626.804519	0.0	-10.606000	6.000668e-29	762.037487	1.602114e-148
S&P 500 Utilities	0.022159	1.225315	-12.265321	12.320387	-0.298052	15.955440	26852.775797	0.0	-15.268784	4.748672e-28	1124.513610	1.027110e-225
CPU	5.0914	0.4342	3.8944	6.0193	-0.5652	2.8647	6.4817	0.0391	-3.9130	0.0159	50.0507	0.0000

Le tableau ci-dessus résume les principales statistiques sur les rendements des indices sectoriels étudiés. On note que le kurtosis de l'ensemble des rendements sectoriels excède trois, ce qui est caractéristique de distributions leptocurtiques avec queues lourdes. Les statitsques de Jarque-Bera pour l'ensemble des rendements sont significatives au seuil de 1%, confirmant le rejet de l'hypothèse de normalité des rendements. Tous les tests ADF rejettent l'hypothèse nulle, indiquant que les séries des rendements n'ont pas de racine unitaire et sont stationnaires de même que la CPU. Toutes les séries valident le test d'effet ARCH qui examine la présence d'une hétéroscléasticité conditionnelle avec des retards de 1 à 20. Au regard de ces résultats, une modélisation GARCH semble appropriée.

Chapitre 3 —

Résultats empiriques de l'étude

3.1 Effets de l'indice CPU sur les indices sectoriels

Cette section va examiner l'impact de la CPU sur la volatilité de long terme des indices sectoriels. Pour ce faire, un modèle GARCH - MIDAS univarié est estimé pour chaque indice sectoriel en considérant comme variable exogène la CPU (ou sa volatilité). La plage des données considérées pour la modélisation va du 03 Novembre 2014 au 30 Septembre 2024.

3.1.1 Impact de la CPU en niveau

Les résultats des estimations des modèles GARCH-MIDAS pour chacun des indices sectoriels sont consignés dans le tableau 3.1 ci-après. La valeur de K pour chaque modèle est déterminée dans une plage de 0 à 30 mois, et la volatilité de long terme est estimée ici dans sans forme non logarithmique. D'emblée, concernant la volatilité de court terme, la totalité des valeurs de α décrivant l'impact des chocs de volatilité passés sur la volatilité actuelle sont significativement non nulles. Les résultats stipulent également que les fluctuations historiques impactent la volatilité actuelle et que la volatilité montre une forte persistance et une mémoire de long terme (β significativement non nul pour tous les indices sectoriels). Aussin la somme de α et β est approximativement égale à 1, ce qui indique que la volatilité à court terme reviendra à sa tendance de long terme. Ces résultats d'estimation suggèrent également que le modèle GARCH-MIDAS est stable.

Le paramètre estimé θ est significatif et positif pour huit des indices sectoriels considérés ; ce qui signifie qu'une hausse de l'indice CPU accroît la volatilité dans ces secteurs. La CPU n'a pas d'effet significatif sur trois des secteurs étudiés à savoir : Consumer Staples,

Financials et Health Care. Les secteurs les plus affectés sont celui du Real Estate et des Utilities. En effet la CPU explique respectivement 38% et 33% de la volatilité de long terme de ces secteurs.

TABLE 3.1 – Résultats des modèles GARCH-MIDAS avec CPU

Secteur	Paramètres GARCH			Coefficients			Statistiques		
	μ	α	β	m	θ	w	LLH	BIC	VR (%)
Comm. Services	0.058** (0.029)	0.113*** (0.023)	0.828*** (0.036)	-6.648* (3.822)	1.406* (0.731)	2.795** (1.103)	-3163	6371	22.34
Cons. Discretionary	0.085*** (0.023)	0.125*** (0.017)	0.851*** (0.019)	-9.092** (3.610)	1.879*** (0.686)	1.000 (0.674)	-2970	5984	22.89
Consumer Staples	0.041** (0.016)	0.126*** (0.027)	0.827*** (0.039)	-4.125* (2.409)	0.739 (0.466)	1.444 (0.896)	-2205	4456	5.57
Energy	0.042 (0.033)	0.095*** (0.025)	0.890*** (0.028)	-9.415** (4.702)	2.036** (0.915)	1.413*** (0.523)	-3540	7126	24.17
Financials	0.086*** (0.023)	0.171*** (0.034)	0.783*** (0.042)	1.207 (2.938)	-0.126 (0.558)	28.083 (116.179)	-2916	5877	0.21
Health Care	0.054*** (0.018)	0.104*** (0.024)	0.861*** (0.036)	-2.352 (3.917)	0.436 (0.714)	1.000 (10.416)	-2432	4909	2.22
Industrials	0.059*** (0.021)	0.122*** (0.031)	0.842*** (0.042)	-3.299* (1.986)	0.696* (0.381)	1.000 (2.115)	-2766	5577	4.89
Info. Tech.	0.131*** (0.029)	0.139*** (0.023)	0.810*** (0.030)	-8.958** (4.181)	1.868** (0.794)	3.693* (2.089)	-3239	6524	24.61
Materials	0.049** (0.024)	0.108*** (0.032)	0.864*** (0.047)	-5.192* (2.739)	1.088** (0.527)	1.220* (0.674)	-2899	5842	11.59
Real Estate	0.046** (0.022)	0.105*** (0.025)	0.849*** (0.038)	-11.37*** (2.839)	2.252*** (0.546)	1.395** (0.585)	-2820	5685	38.27
Utilities	0.047** (0.022)	0.100*** (0.023)	0.841*** (0.036)	-9.692*** (2.320)	1.890*** (0.445)	1.411*** (0.315)	-2673	5391	33.74

Note : *, ** et *** indiquent une significativité aux niveaux de 10%, 5% et 1% respectivement. LLH : Log-vraisemblance ; BIC : Critère d'information bayésien ; VR : Variance Ratio. Entre parenthèses ce sont les écarts-types des estimateurs.

3.1.2 Impact de la volatilité de la CPU

Dans cette section, l'on veut analyser l'impact de la volatilité de la CPU sur les indices sectoriels. Pour ce faire, on commence par estimer la volatilité de la CPU (CPUv) en suivant l'approche de Jia et al (2024). Elle consiste alors à estimer le modèle autoregressif donné par l'équation (3.1). En particulier, les carrés des résidus estimés $\hat{\varepsilon}_t^2$ de cette régression servent à extraire la volatilité de la variable macroéconomique CPU :

$$CPU_t = \sum_{i=1}^{12} \alpha_i D_i + \sum_{i=1}^{12} \beta_i CPU_{t-i} + \varepsilon_t \quad (3.1)$$

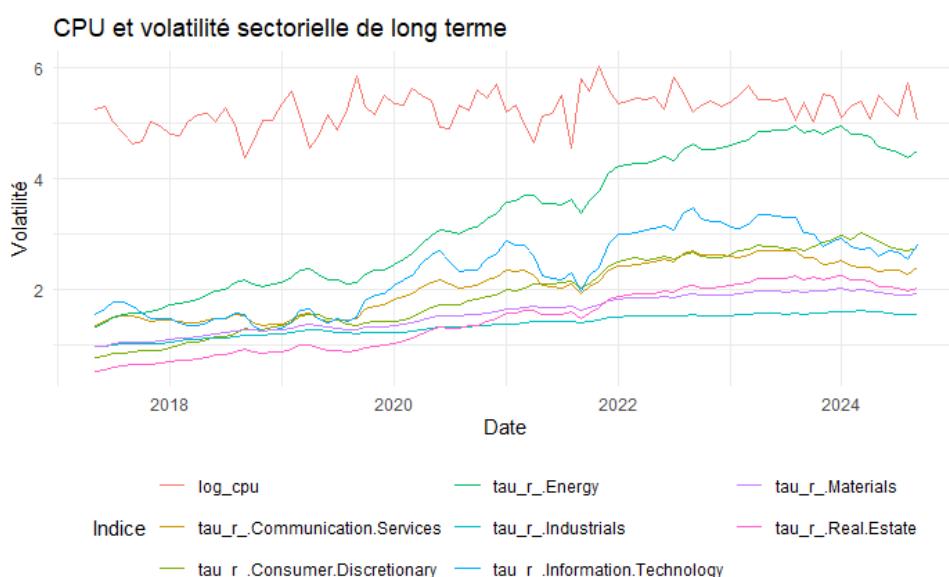
Le tableau 3.2 présente les résultats des estimations des modèles GARCH-MIDAS avec la volatilité de la CPU comme variable exogène. On peut avoir comme précédemment que les modèles GARCH-MIDAS sont stables. Aussi, sur les 11 indices sectoriels considérés, seuls deux sont significativement affectés par la volatilité de la CPU. Le secteur des Communications services est positivement et significativement affecté au seuil de 10%.

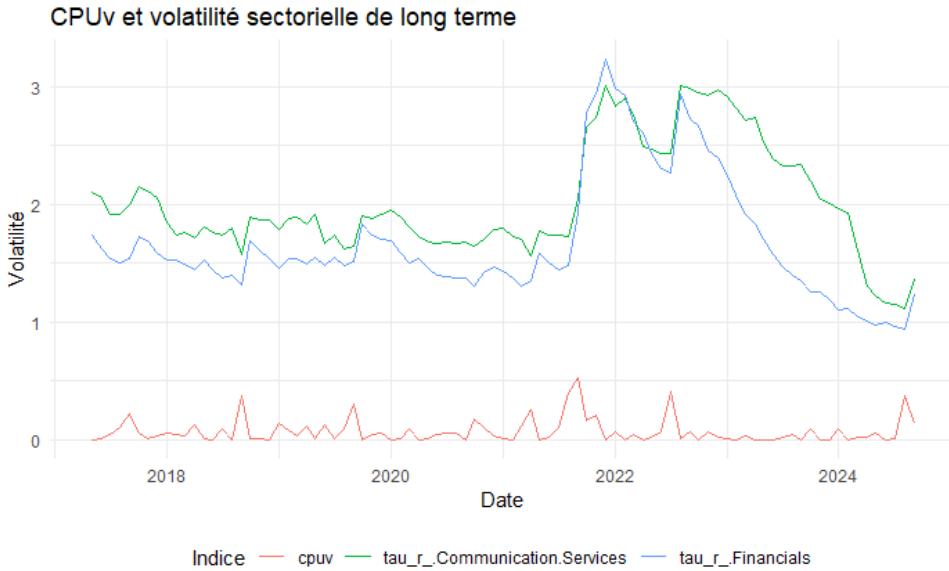
TABLE 3.2 – Résultats des modèles GARCH-MIDAS avec CPUv

Secteur	Paramètres GARCH			Coefficients			Statistiques		
	μ	α	β	m	θ	w	LLH	BIC	VR
Comm. Services	0.063** (0.029)	0.115*** (0.024)	0.824*** (0.038)	-0.447 (0.621)	14.912* (8.018)	1.088*** (0.293)	-3164	6374	20.85
Cons. Discretionary	0.082*** (0.024)	0.124*** (0.017)	0.859*** (0.018)	0.844 (0.632)	-4.438 (8.990)	4.125 (3.411)	-2981	6006	3.16
Consumer Staples	0.042*** (0.016)	0.127*** (0.027)	0.821*** (0.039)	-0.873** (0.413)	7.632 (5.323)	1.866*** (0.361)	-2205	4456	7.40
Energy	0.044 (0.034)	0.095*** (0.027)	0.891*** (0.031)	0.822 (0.933)	2.887 (14.518)	2.195 (1.444)	-3547	7140	0.75
Financials	0.089*** (0.023)	0.175*** (0.032)	0.762*** (0.040)	-0.451 (0.346)	12.678*** (3.899)	1.959*** (0.333)	-2910	5865	16.10
Health Care	0.055*** (0.018)	0.108*** (0.021)	0.850*** (0.034)	-0.604 (0.402)	6.757 (4.557)	2.353*** (0.494)	-2431	4907	7.38
Industrials	0.059*** (0.021)	0.126*** (0.031)	0.836*** (0.042)	-0.351 (0.425)	8.656* (5.200)	2.171*** (0.667)	-2766	5577	9.35
Info. Tech.	0.128*** (0.030)	0.135*** (0.022)	0.830*** (0.028)	0.522 (0.908)	4.318 (11.759)	1.499 (0.920)	-3245	6535	1.56
Materials	0.046* (0.024)	0.110*** (0.032)	0.860*** (0.047)	-0.064 (0.515)	6.585 (6.387)	1.864** (0.752)	-2901	5848	4.92
Real Estate	0.045** (0.022)	0.098*** (0.022)	0.878*** (0.027)	0.412* (0.227)	-1.710 (1.205)	30.469 (20.670)	-2832	5708	3.49
Utilities	0.046** (0.022)	0.099*** (0.021)	0.866*** (0.030)	0.308 (0.306)	-2.493 (3.532)	5.487 (3.715)	-2686	5417	2.29

Note : *, ** et *** indiquent une significativité aux niveaux de 10%, 5% et 1% respectivement. LLH : Log-vraisemblance ; BIC : Critère d'information bayésien ; VR : Variance Ratio. Entre parenthèses ce sont les écarts-types des estimateurs.

Une hausse de la volatilité de la CPU a donc tendance à accroître la volatilité de ce secteur. De même, le secteur Financials est affecté significativement par la CPUv au seuil de 1%. La CPUv contribue respectivement à 20% et 16% de la volatilité de long terme sur ces secteurs. Aussi, en faisant le parallèle avec les résultats précédents sur la CPU en niveau, on constate que moins de secteurs sont impactés par la volatilité de la CPU. Par ailleurs, le secteur financier est affecté par la CPUv ce qui n'était pas le cas de la CPU.





Les deux figures ci-dessus permettent de visualiser l'évolution de la CPU et la CPUv ainsi que les volatilités de long terme des différents indices sectoriels affectés dans les différents modèles GARCH-MIDAS estimés plus haut. Leur analyse permet de mieux comprendre le contraste observé entre les modèles GARCH-MIDAS avec CPU en niveau et ceux avec la CPUv. On observe sur le premier graphique que les chocs sur la CPU se répercutent sur les indices sectoriels. Sur le second on constate que les chocs à la hausse de la CPUv se répercutent sur les deux secteurs affectés. On observe que la volatilité de long terme des secteurs financiers et celui des Communication Services sont assez corrélés. Ceci pourrait expliquer pourquoi le secteur financier est affecté dans le modèle GARCH-MIDAS avec la CPUv. En effet ce dernier est corrélé au secteur Communication Services qui lui était déjà affecté par la CPU en niveau.

3.2 Corrélations dynamiques

Dans cette section, on utilise un modèle DCC-GARCH pour examiner les mouvements joints de la CPU (ou de CPUv) avec la volatilité de chacun des indices sectoriels, ceci au fil du temps. Le modèle utilisé requiert que les séries utilisées soient de même fréquence, c'est pourquoi il était nécessaire de mensualiser les séries de volatilité des indices sectoriels. Pour ce faire, on calcule les volatilités mensuelles pour chaque indice sectoriel en calculant la moyenne mensuelle des carrés des résidus e_{it}^2 du modèle GARCH(1,1) estimé

sur la série des rendements de l'indice (r_{it}). La Figure 3.1 ci-après montre l'évolution du lien entre CPU et la volatilité des différents indices sectoriels. On observe que les co-mouvements sont en général positifs, ce qui est consistant avec les résultats des modèles GARCH-MMIDAS estimés. On constate que ces co-mouvements sont influencés par des événements historiques majeurs. Notamment, on observe une hausse des co-mouvements après l'adoption de l'accord de Paris en décembre 2015 sur la plupart des secteurs. On observe ensuite une baisse après l'implémentation de l'accord de Paris qui s'accentue avec la COVID avant de repartir à la hausse en 2020. De façon similaire, avec la CPUp on note des hausses de corrélations en 2020 et des baisses au début de la guerre en Ukraine.

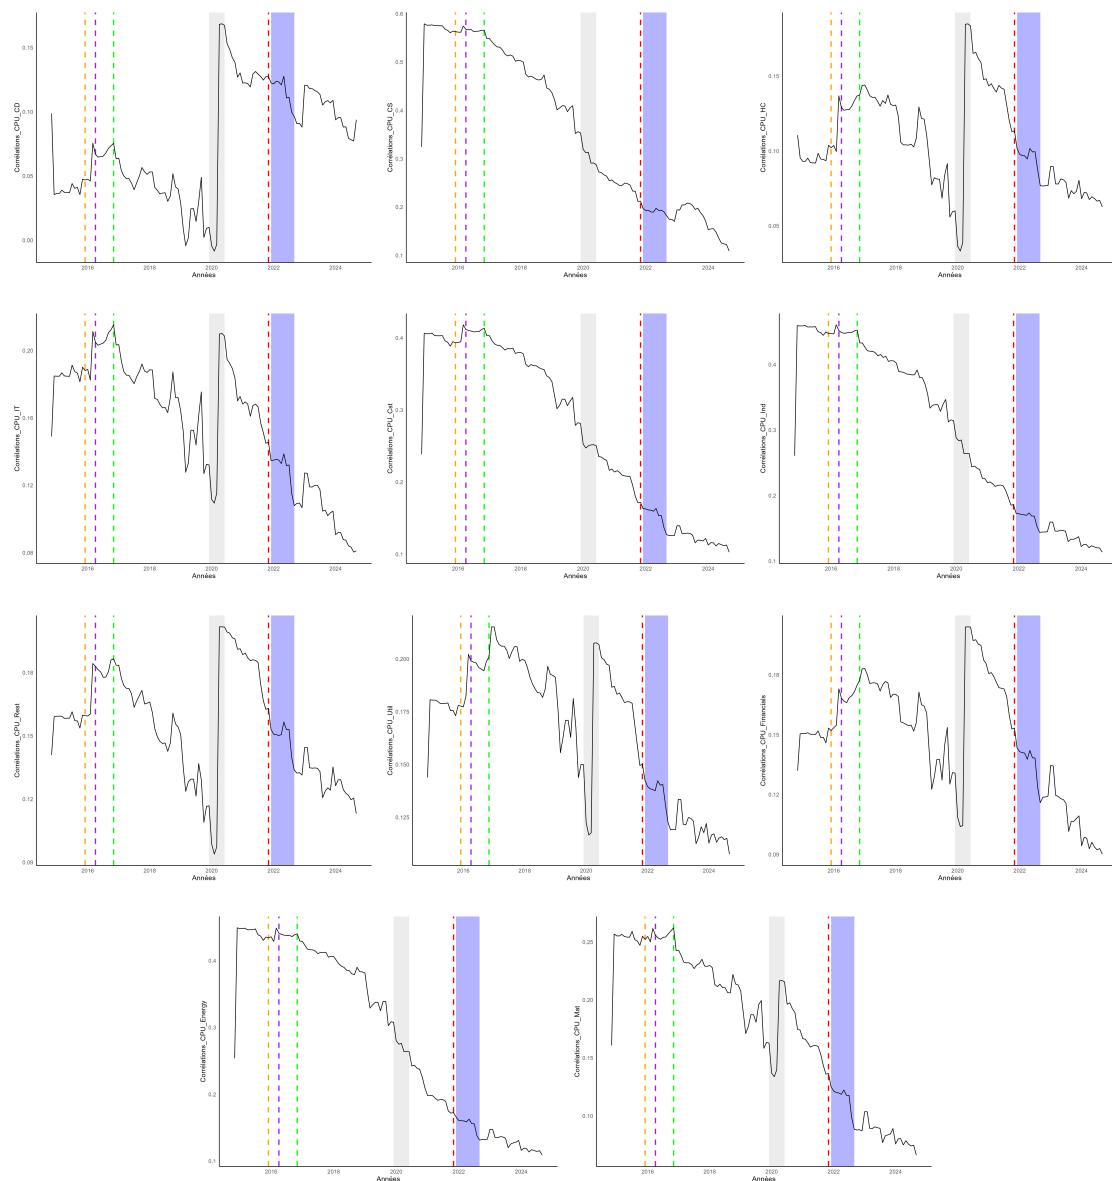


FIGURE 3.1 – Co-mouvements de la CPU et des indices sectoriels

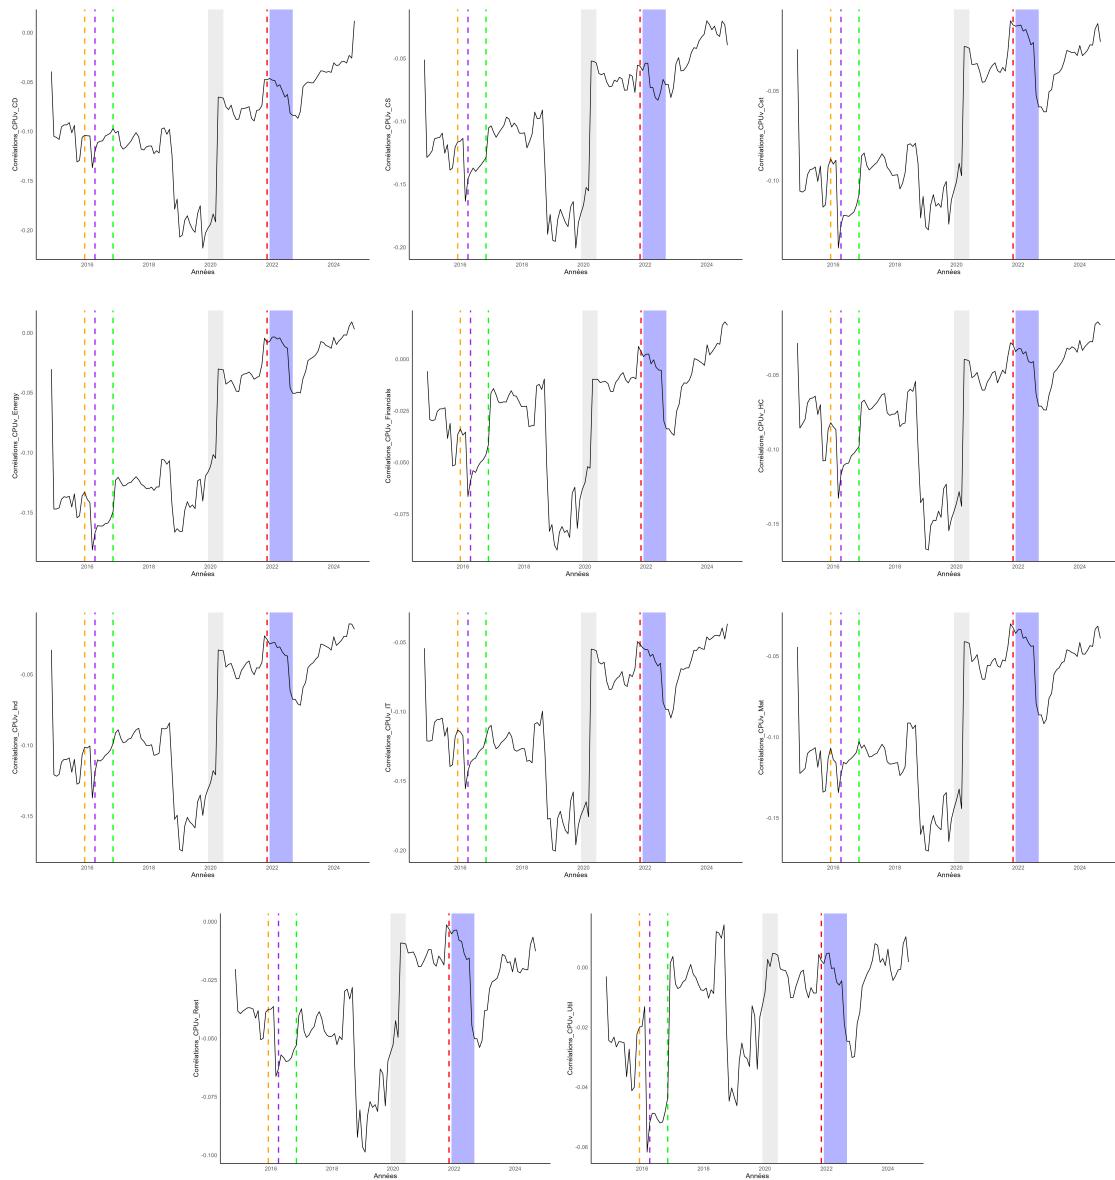


FIGURE 3.2 – Co-mouvements de la CPUv et des indices sectoriels

Conclusion

Dans ce travail, il était question d'étudier la transmission des risques climatiques aux marchés financiers en adoptant une approche économétrique fondée sur une littérature scientifique solide. S'inscrivant dans la continuité des recherches antérieures, la contribution principale de ce travail réside dans l'analyse sectorielle de l'impact des risques climatiques quantifiés ici par l'indice CPU, sur les différents secteurs du S&P 500.

Pour ce faire, deux méthodologies ont été retenues : les modèles GARCH-MIDAS et le DCC-GARCH. Ces approches ont permis d'examiner à la fois les effets du niveau et de la volatilité de l'indice CPU sur les rendements sectoriels du S&P 500, ainsi que l'évolution temporelle des corrélations dynamiques entre ces indices sectoriels et la CPU.

Les liens entre les corrélations dynamiques et certains événements marquants liés aux politiques climatiques ou au contexte géopolitique mondial ont été mis en évidence. Cette étude a ainsi révélé plusieurs résultats significatifs. Dans un premier temps, le choix de la mise en place du modèle GARCH-MIDAS a été justifié en montrant avec des tests d'effets ARCH que tous les log-rendements des indices sectoriels du S&P 500 sont modélisables avec un modèle GARCH. En observant ces rendements sectoriels et la CPU, l'on constate une évolution temporelle croissante à la hausse de ces rendements marquée par des périodes de chutes (autour de 2020 pour le Covid et 2022 pour la Guerre en Ukraine) avec des effets plus ou moins prononcés selon les secteurs.

L'analyse à l'aide des modèles GARCH-MIDAS révèle une hétérogénéité sectorielle marquée dans la réponse de la volatilité de long terme à l'indice d'incertitude climatique (CPU) et à sa volatilité (CPUV). Lorsqu'on considère la CPU en niveau comme variable explicative, huit secteurs sur onze présentent un effet positif et significatif, suggérant que l'incertitude climatique tend à accroître la volatilité de long terme dans ces secteurs. Les effets sont particulièrement prononcés pour les secteurs du Real Estate et des Utilities, où la CPU explique respectivement 38% et 33% de la volatilité. À l'inverse, les secteurs

Consumer Staples, Financials et Health Care ne sont pas significativement affectés par la CPU, traduisant une sensibilité plus faible ou une meilleure résilience à l'incertitude climatique.

En revanche, l'impact de la volatilité de la CPU (CPUv) est plus restreint. Seuls deux secteurs Communication Services et Financials sont significativement affectés, avec une contribution respective de 20% et 16% à leur volatilité de long terme. Il sied de relever que le secteur Financials, initialement non affecté par la CPU en niveau, réagit significativement à la CPUv, ce qui peut s'expliquer par sa forte corrélation avec Communication Services, lui-même sensible aux chocs climatiques en niveau. Ce contraste met en évidence que certains secteurs réagissent plus aux niveaux d'incertitude, tandis que d'autres réagissent davantage à la variabilité de cette incertitude. Ces résultats soulignent donc l'importance de prendre en compte la nature du signal climatique (niveau ou volatilité) et les caractéristiques sectorielles spécifiques pour mieux anticiper les effets différenciés de l'incertitude climatique sur les marchés financiers.

L'étude des corrélations dynamiques via le modèle DCC-GARCH a permis de mettre en évidence des co-mouvements significatifs et généralement positifs entre la CPU (ou sa volatilité CPUv) et la volatilité des indices sectoriels. Les résultats montrent que ces corrélations varient dans le temps et réagissent aux grands événements politiques ou géopolitiques. On observe par exemple une hausse marquée des co-mouvements après l'adoption de l'accord de Paris en décembre 2015, suivie d'un affaiblissement progressif, accentué par la crise du COVID-19, puis d'un regain d'intensité à partir de 2020. Concernant la CPUv, les corrélations avec les secteurs augmentent aussi en 2020 avant de diminuer au début de la guerre en Ukraine. Cependant, d'un point de vue sectoriel, bien que les corrélations évoluent globalement dans le même sens, on observe que leur volatilité temporelle est plus prononcée pour certains secteurs que pour d'autres, ce qui permet de regrouper les secteurs selon cette sensibilité. En effet, les secteurs Energy, Industrials, Consumer Staples et Consumer Services présentent une décroissance relativement stable de leur corrélation avec la CPU en niveau au fil du temps, avec une sensibilité moins marquée lors des épisodes d'événements climatiques ou de tensions géopolitiques. À l'inverse, les autres secteurs affichent une évolution plus erratique de leurs corrélations également orientée à la baisse mais nettement plus affectée par les événements majeurs considérés.

Certains résultats semblent intuitifs que d'autres. En effet, les secteurs Real Estate et Utilities sont fortement exposés à la régulation climatique (normes énergétiques, pression sur les émissions, etc.), donc il est cohérent de constater que leurs corrélations avec la CPU sont élevées et sensibles aux événements climatiques majeurs (comme l'Accord de Paris ou la COP26). La forte réactivité du secteur Financials à la volatilité de la CPU (CPUv) s'explique également de manière intuitive : les acteurs financiers intègrent les risques climatiques dans leurs modèles de gestion du risque, stress tests réglementaires ou stratégies d'investissement. Cela justifie une sensibilité accrue à l'incertitude climatique. Néanmoins, l'on aurait pu s'attendre à une forte sensibilité du secteur Energy aux chocs climatiques et à l'incertitude politique associée (carbon pricing, transition énergétique, taxes sur le pétrole/gaz, etc.). Une hypothèse explicative pourrait être que les grandes entreprises du secteur ont déjà intégré ces risques dans leur pricing ou bénéficient de soutiens politiques/réglementaires stables. Par ailleurs, les investisseurs peuvent percevoir des titres verts donc moins volatils en réaction aux nouvelles incertitudes.

Dans l'optique d'évaluer la robustesse des résultats, l'analyse précédente a été reproduite en utilisant un autre indicateur : l'indice CRMI (Critical Raw Materials Index, Hasse J.-B. Nobletz C., 2024). Cet indice financier de référence suit la dynamique des prix au comptant hebdomadaires de 28 métaux essentiels à la transition énergétique, couvrant six secteurs clés de l'énergie propre, sur la période 2012–2025. Après estimations des modèles GARCH-MIDAS en prenant la CRMI comme variable exogène, les premiers résultats obtenus semblent cohérents avec ceux observés précédemment avec l'indice CPU en niveau.

Dans une perspective d'approfondissement, il serait intéressant d'étudier les effets de débordement de volatilité entre les secteurs à l'aide d'un modèle TVP-VAR, afin de mieux comprendre les canaux de transmission intersectorielle et le sens des chocs. Enfin, il serait pertinent d'explorer une extension du cadre GARCH multivarié (DCC-GARCH), en intégrant une logique de changement de régime, afin d'analyser les dynamiques de dépendance dans des phases de fort lien versus faible lien entre l'incertitude climatique et les secteurs étudiés.

Bibliographie

1. Ding, Z., & Granger, C. W. J. (1996). Modeling volatility persistence of speculative returns : A new approach. *Journal of Econometrics*, 73(1), 185–215. [https://doi.org/10.1016/0304-4076\(95\)01736-2](https://doi.org/10.1016/0304-4076(95)01736-2)
2. Ding, Z., & Granger, C. W. J. (2016). Modeling long memory volatility and long memory trading volume with applications to stocks and futures. *Studies in Nonlinear Dynamics & Econometrics*, 20(4), 439–459. <https://doi.org/10.1515/snnde-2014-0052>
3. Engle, R., Giglio, S., Kelly, B., Lee, H., & Stroebel, J. (2017). Hedging Climate Change News. *NBER Working Paper No. 25791*.
4. Engle, R. F., Ghysels, E., & Sohn, B. (2013). Stock market volatility and macroeconomic fundamentals. *Review of Economics and Statistics*, 95(3), 776–797. https://doi.org/10.1162/REST_a_00313
5. Engle, R. F., & Lee, G. G. J. (1999). A long-run and short-run component model of stock return volatility. In R. F. Engle & H. White (Eds.), *Cointegration, Causality, and Forecasting : A Festschrift in Honor of Clive W. J. Granger* (pp. 475–497). Oxford University Press.
6. Ghani, U., Zhu, B., Ma, F., & Ghani, M. (2024). Climate Change and Volatility Forecasting : Novel Insights from Sectoral Indices. *Journal of Climate Finance*, 6, 100034.
7. Ghani, U., Bho Zhu, F. Ma, & M. Ghani. (2024). Climate Change and Sectoral Indices. *Journal of Climate Finance*, 6.
8. Hasse, J.-B., & Nobletz, C. (2024). Critical Raw Materials Index (CRMI). *AMSE Working Paper No. 2024-27*. Aix-Marseille School of Economics.
9. Jia, S., Guo, N., & Jin, J. (2024). Climate Policy Uncertainty Risk and Sovereign Bond Volatility. *Journal of Cleaner Production*, 434, 140145.

10. Maheu, J. M., & McCurdy, T. H. (2005). News arrival, jump dynamics, and volatility components for individual stock returns. *Journal of Finance*, 60(3), 1203–1241.
<https://doi.org/10.1111/j.1540-6261.2005.00759.x>
11. Pereira, J., Thomas, L., & Silva, R. (2023). Climate-Related Risks, Opportunities, and Financial Impacts. *Environmental Economics and Policy Studies*, 25, 89-115.
12. Zhang, D., & Wei, Y. (2016). Dependences and Volatility Spillovers Between the Oil and Stock Markets. *Energy Economics*, 54, 59-71.

Annexe

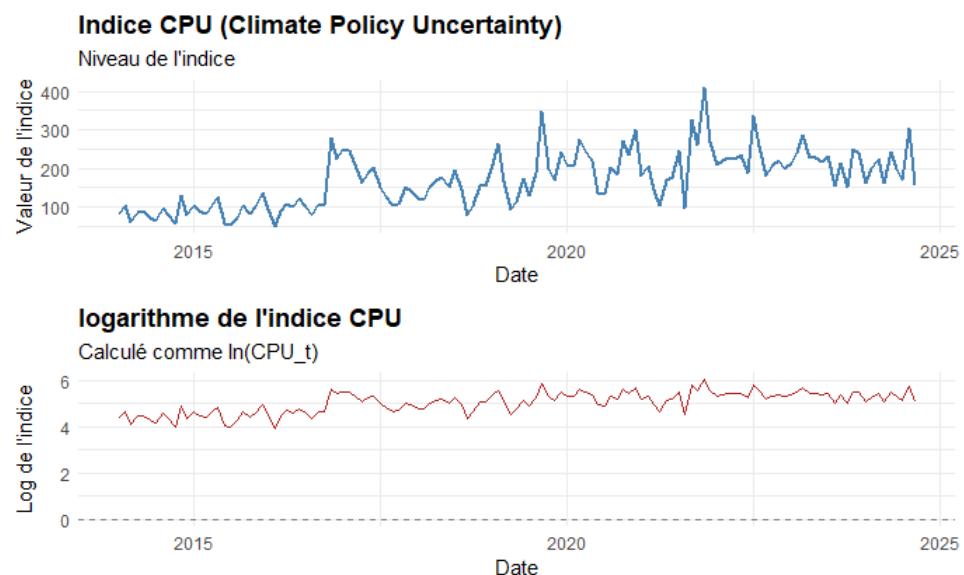


FIGURE 3.3 – Indice CPU

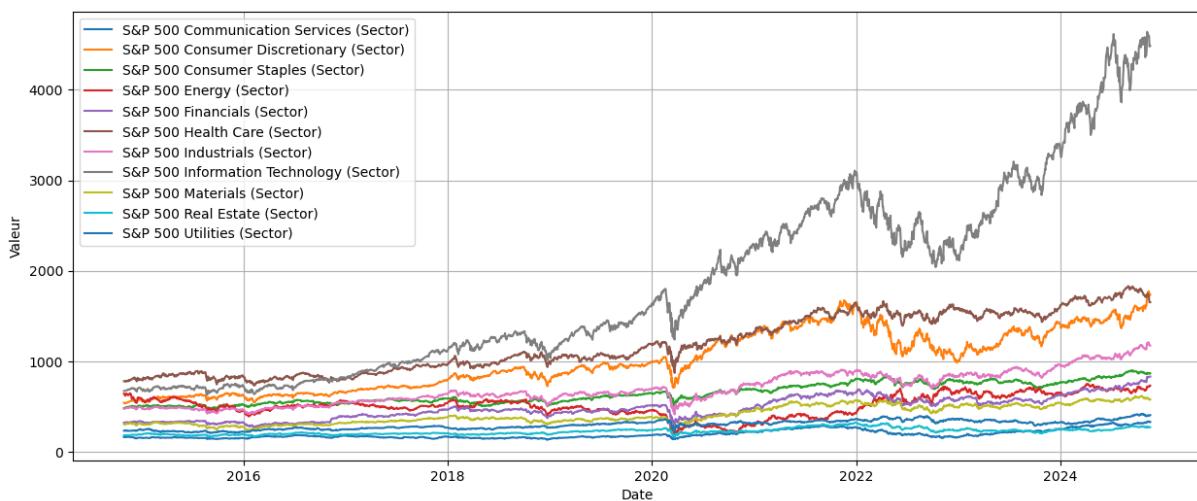


FIGURE 3.4 – Représentation conjointe des indices sectoriels